

机器学习基础概念

Machine Learning Fundamentals

一、什么是机器学习

机器学习 (Machine Learning, ML) 是人工智能的一个子领域，它使计算机系统能够从数据中自动学习和改进，而无需进行明确的程序编写。机器学习的核心思想是通过算法从大量数据中提取模式和规律，并利用这些模式进行预测或决策。

机器学习的关键要素包括：

- 数据 (Data)：学习的基础，包括训练集、验证集和测试集
- 模型 (Model)：从数据中学习到的数学表示
- 算法 (Algorithm)：用于训练模型的方法
- 特征 (Feature)：描述数据的属性或变量
- 标签 (Label)：监督学习中的目标变量

二、机器学习的类型

2.1 监督学习 (Supervised Learning)

监督学习是最常见的机器学习类型。在监督学习中，模型从带有标签的训练数据中学习，即每个训练样本都有对应的正确答案。模型的目标是学习输入特征到输出标签的映射关系。

常见任务：

- 分类 (Classification)：预测离散类别（如垃圾邮件识别、图像分类）
- 回归 (Regression)：预测连续数值（如房价预测、销量预测）

2.2 无监督学习 (Unsupervised Learning)

无监督学习处理没有标签的数据。模型需要自行发现数据中的结构和模式。

常见任务：

- 聚类 (Clustering)：将数据分成不同的组（如客户分群、文档分类）
- 降维 (Dimensionality Reduction)：减少特征数量（如PCA、t-SNE）
- 异常检测 (Anomaly Detection)：识别异常数据点

2.3 强化学习 (Reinforcement Learning)

强化学习通过智能体 (Agent) 与环境的交互来学习最优策略。智能体通过尝试不同的动作，根据获得的奖励或惩罚来调整行为，目标是最大化累积奖励。

应用场景：游戏AI (AlphaGo)、机器人控制、自动驾驶、推荐系统

三、常见机器学习算法

3.1 线性回归 (Linear Regression)

线性回归是最基础的回归算法，用于预测连续数值。它假设输出变量与输入特征之间存在线性关系。

数学模型： $y = w_0x_0 + w_1x_1 + \dots + w_nx_n + b$

优点：简单、可解释性强、计算效率高

缺点：只能捕捉线性关系、对异常值敏感

3.2 决策树 (Decision Tree)

决策树是一种树形结构的分类和回归算法。它通过一系列的判断规则对数据进行分类或预测。

优点：易于理解和解释、可以处理非线性关系、不需要特征缩放

缺点：容易过拟合、对数据变化敏感

3.3 随机森林 (Random Forest)

随机森林是一种集成学习方法，通过构建多个决策树并取其平均结果来提高预测准确性。

核心思想：Bagging + 特征随机选择

优点：准确率高、不容易过拟合、可以处理高维数据

缺点：模型复杂、训练时间较长

3.4 支持向量机 (SVM)

支持向量机是一种强大的分类算法，其核心思想是找到一个最优的超平面来分隔不同类别的数据。

关键概念：

- 支持向量：距离超平面最近的数据点
- 核函数：将数据映射到高维空间（如RBF核、多项式核）

优点：在高维数据上表现好、泛化能力强

缺点：对大规模数据训练慢、对参数和核函数选择敏感

3.5 K近邻 (KNN)

KNN是一种基于实例的学习算法，其核心思想是：如果一个样本在特征空间中的K个最相似样本中的大多数属于某个类别，则该样本也属于这个类别。

关键参数：K值的选择（通常通过交叉验证确定）

优点：简单直观、无需训练过程

缺点：计算复杂度高、对高维数据效果差

3.6 K-means聚类

K-means是最常用的聚类算法，用于将数据分成K个簇。

算法步骤：

1. 随机选择K个初始中心点
2. 将每个数据点分配到最近的中心点
3. 重新计算每个簇的中心点
4. 重复步骤2-3直到收敛

优点：简单高效、易于实现

缺点：需要预先指定K值、对初始中心点敏感

四、模型评估指标

4.1 分类指标

- 准确率 (Accuracy)：正确预测的比例
- 精确率 (Precision)：预测为正例中真正为正例的比例
- 召回率 (Recall)：真正为正例中被正确预测的比例
- F1分数：精确率和召回率的调和平均
- ROC曲线和AUC：评估分类器性能的综合指标

4.2 回归指标

- 均方误差 (MSE)：预测值与真实值差值的平方的平均
- 均方根误差 (RMSE)：MSE的平方根
- 平均绝对误差 (MAE)：预测值与真实值差值的绝对值的平均
- R^2 分数：模型解释数据变异性的比例

五、过拟合与欠拟合

5.1 过拟合 (Overfitting)

过拟合是指模型在训练数据上表现很好，但在新数据上表现差。模型学习到了训练数据中的噪声和细节，而不是真正的规律。

解决方法：

- 增加训练数据
- 使用正则化 (L1、L2正则化)

- 减少模型复杂度
- 使用交叉验证
- 早停 (Early Stopping)

5.2 欠拟合 (Underfitting)

欠拟合是指模型在训练数据和新数据上都表现不好。模型过于简单，无法捕捉数据中的规律。

解决方法：

- 增加模型复杂度
- 添加更多特征
- 减少正则化强度
- 使用更复杂的模型

六、特征工程

特征工程是机器学习中最重要的一环之一，指从原始数据中提取和构建对模型有用的特征。

主要方法：

- 特征缩放：标准化 (Z-score)、归一化 (Min-Max)
- 特征编码：独热编码 (One-Hot)、标签编码 (Label Encoding)
- 特征选择：过滤法、包装法、嵌入法
- 特征提取：PCA、LDA等降维方法
- 特征构造：组合现有特征创建新特征

七、深度学习简介

深度学习是机器学习的一个分支，使用多层神经网络来学习数据的层次化表示。

核心概念：

- 神经网络：由输入层、隐藏层和输出层组成
- 激活函数：ReLU、Sigmoid、Tanh等
- 反向传播：用于训练神经网络的算法
- 梯度下降：优化算法，用于更新模型参数

常见架构：

- 卷积神经网络 (CNN)：用于图像处理
- 循环神经网络 (RNN)：用于序列数据
- Transformer：用于自然语言处理 (如BERT、GPT)
- 生成对抗网络 (GAN)：用于生成新数据